ppo_flow_readable_2026-10-19

PPOの流れと、除去・置換の現状

Actorのパラメータをθ、Criticのパラメータをϕとする。oldは「今回の経験収集時の値」を表す。学習できたことが確認されている置換は、7のAdvantageの調整と、14の勾配ノルム制限の2点。「除去不可（現時点）」は、これまでの実験結果から現在は残すという判断。

1. 状態から、行動分布の平均と状態価値を計算する｜維持

状態s_tをActorとCriticに入力する。

$$\mu_{\text{old}}(s_t) = \mu_{\theta_{\text{old}}}(s_t), \qquad V_{\text{old}}(s_t) = V_{\phi_{\text{old}}}(s_t)$$

$\mu_{\text{old}}(s_t)$は、その状態での行動分布の平均。$V_{\text{old}}(s_t)$は、その状態から先に得られる割引累積報酬の予測。

2. ガウス分布から行動をサンプリングする｜σの調整は除去不可（現時点）／別の調整則は置換候補（未検証）

平均$\mu_{\text{old}}(s_t)$、各行動次元の標準偏差σ_{old}から方策を定め、行動をサンプリングする。

$$\pi_{\text{old}}(\cdot \mid s_t) = \mathcal{N}\left(\mu_{\text{old}}(s_t), \operatorname{diag}(\sigma_{\text{old}}^2)\right), \qquad a_t \sim \pi_{\text{old}}(\cdot \mid s_t)$$

同じサンプリングは、次の式でも表せる。

$$\epsilon_t \sim \mathcal{N}(0, I), \qquad a_t = \mu_{\text{old}}(s_t) + \sigma_{\text{old}} \odot \epsilon_t$$

$\odot$は成分ごとの積。今回のActorでは、σは行動次元ごとに保持する学習可能な量で、状態に直接依存しない。σを固定した条件は複数seedでうまくいかなかったが、到達できた試行もある。報酬に基づく別の調整則は未検証。

3. 行動を実行し、報酬と次状態を得る｜維持

行動を実行して、r_tとs_{t+1}を得る。課題そのものの終了と、時間制限による打ち切りを区別する。

- 課題そのものが終了した場合：その先の価値を0として扱う。

- 時間制限による打ち切り：打ち切り時点の状態価値を使って、その先の報酬を見積もる。

4. 一定量の経験を収集する｜収集方法の変更は未検証

ActorとCriticを更新せずに1〜3を繰り返し、Tステップ分の経験を集める。各時点について、次の情報を保持する。

$$s_t, \quad a_t, \quad r_t, \quad \log \pi_{\text{old}}(a_t \mid s_t), \quad V_{\text{old}}(s_t)$$

加えて、エピソードがどこで終了・打ち切りになったかを保持する。この経験のまとまりをRolloutと呼ぶ。

5. GAEでAdvantageを計算する｜除去・置換は未検証

まず、各時点のTD誤差を計算する。

$$\delta_t = r_t + \gamma V_{\text{old}}(s_{t+1}) - V_{\text{old}}(s_t)$$

次に、同じエピソード内では、後ろの時点から順に次の計算を行う。

$$A_t^{\text{raw}} = \delta_t + \gamma\lambda A_{t+1}^{\text{raw}}$$

γは割引率、λは後続のTD誤差をどの程度反映するかを決める係数。課題終了・時間制限による打ち切り・収集区間の末尾では、この式のA_{t+1}^{raw}を0として計算を区切る。真の終端では、TD誤差に使う次状態価値も0とする。

得られたA_t^{raw}は、同じRolloutの学習中は固定する。GAE原論文

6. Criticの学習目標を作る｜目標の作り方・固定方法の置換は未検証

$$Y_t = V_{\text{old}}(s_t) + A_t^{\text{raw}}$$

学習中はY_tを固定し、現在のCriticの予測をこの値に近づける。Criticが更新されても、同じRolloutのY_tは作り直さない。

7. Actor用Advantageを調整する｜置換可能（確認済み）

置換前：ミニバッチ内の標準化

ミニバッチB内の平均$\bar{A}_B$を引き、標準偏差s_Bで割る。

$$\bar{A}_B = \frac{1}{|B|}\sum_{t\in B} A_t^{\text{raw}}, \qquad s_B = \mathrm{Std}_{t\in B}(A_t^{\text{raw}})$$

–

$$A_t^{\text{used}} = \frac{A_t^{\text{raw}} - \bar{A}_B}{s_B + \varepsilon}$$

置換後：過去のRolloutに基づくRunning RMSで除算

$$A_t^{\text{used}} = \frac{A_t^{\text{raw}}}{R_{\text{past}} + \varepsilon}$$

$R_{\text{past}} > 0$は過去のAdvantageの二乗平均の履歴から求める値。計算方法は17に示す。

変更点は、平均を差し引かないため元のAdvantageの符号を保つこと、現在のミニバッチではなく過去のRolloutを参照すること、今回の全epochで同じ尺度を使うこと。

Criticの目標Y_tには、この調整を加えない。

8. ミニバッチに分ける｜複数経験の集約は除去不可（現時点）

収集データをシャッフルし、複数の経験からなるミニバッチBを取り出す。経験1件から得られる勾配をg_tとすると、更新に使う勾配は次の平均になる。

$$g_B = \frac{1}{|B|} \sum_{t \in B} g_t$$

$|B| = 1$とした条件は複数seedでうまくいかなかった。ただし、バッチサイズの変更では更新回数も変わるため、原因を勾配平均の有無だけに限定しない。シャッフル自体の必要性は未検証。

9. 同じ経験を、現在のモデルで再評価する｜維持

保存したs_t, a_tに対して、次を計算する。

$$\log \pi_\theta(a_t \mid s_t), \qquad V_\phi(s_t)$$

行動a_tを選び直したり、新しい報酬を取得したりはしない。

10. 方策比を計算する｜除去・置換は未検証

$$\rho_t(\theta) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)} = \exp[\log \pi_\theta(a_t \mid s_t) - \log \pi_{\text{old}}(a_t \mid s_t)]$$

収集時と現在とで、同じ行動の確率密度を比較する。分母は固定し、分子は更新後のActorで計算し直す。

11. Actorの損失を計算する｜クリッピングの除去・置換は未検証

クリッピング幅をcとする。

$$L_A(\theta) = -\frac{1}{|B|}\sum_{t\in B}\min\left[\rho_t(\theta)A_t^{\text{used}},\ \text{clip}(\rho_t(\theta),1-c,1+c)A_t^{\text{used}}\right]$$

この損失を小さくする方向にActorを学習する。基本となる方向は、Advantageが正ならその行動の確率密度を増やし、負なら減らすこと。

クリッピングは、$A_t^{\text{used}} > 0$で$\rho_t > 1+c$の場合、または$A_t^{\text{used}} < 0$で$\rho_t < 1-c$の場合に、そのサンプルからの勾配寄与を0にする。全サンプルに対する方策比が必ずこの範囲内に収まるという保証ではない。PPO原論文

12. Criticの損失を計算する｜維持

$$L_V(\phi) = \frac{1}{|B|}\sum_{t\in B}\left(V_\phi(s_t) - Y_t\right)^2$$

現在の予測$V_\phi(s_t)$と固定した目標Y_tの二乗誤差を小さくする。価値関数クリッピングは使わない。

13. 誤差逆伝播で勾配を計算する｜維持

Critic損失の重みをc_Vとして、全体の損失を定める。

$$L = L_A + c_V L_V$$

この合計損失に対し、誤差逆伝播を1回行う。Actor用とCritic用に誤差逆伝播を別々に実行する方式へ置換したわけではない。

今回の構成ではActorとCriticが学習パラメータを共有せず、AdvantageとCritic目標も固定値として扱うため、勾配は次のように分かれる。

$$g_A = \nabla_\theta L = \nabla_\theta L_A, \qquad g_C = \nabla_\phi L = \nabla_\phi(c_V L_V)$$

これは置換前から同じ。今回分離したのは、求めた勾配に対する14のノルム制限。Adamも共通のものを使って更新する。収集時の確率密度、Advantage、Criticの目標には勾配を流さない。

14. 勾配ノルムを制限する｜分離への置換可能（確認済み）

置換前：ActorとCriticをまとめて制限

両者を合わせた勾配ノルムをG、上限をCとする。

$$G = \sqrt{\|g_A\|_2^2 + \|g_C\|_2^2}$$

$$u = \frac{C}{\max(C, G)}, \qquad (\tilde{g}_A, \tilde{g}_C) = (u g_A, u g_C)$$

同じ係数uを両方に掛けるため、Criticの勾配が大きいことによってActorの勾配も縮小され得る。

置換後：ActorとCriticを別々に制限

$$\tilde{g}_A = \frac{C_A}{\max(C_A, \|g_A\|_2)} g_A$$

$$\tilde{g}_C = \frac{C_C}{\max(C_C, \|g_C\|_2)} g_C$$

ActorはActor自身の勾配ノルムと上限C_A、CriticはCritic自身の勾配ノルムと上限C_Cで調整する。この分離への置換後も学習できたことを確認している。

各ネットワーク内で全体の勾配情報を使う点は残る。制限を完全に除去できるかは未検証。ここで制限するのは勾配ノルムであり、Adam適用後のパラメータ変化量そのものではない。

15. Adamでパラメータを更新する｜Adamは維持／σの別の調整則は置換候補（未検証）

制限後の勾配をAdamに渡して、ActorのθとCriticのϕを更新する。

- Actor：平均$\mu_\theta(s)$を決める結合・バイアスと、標準偏差を決めるパラメータを更新する。
- Critic：価値予測$V_\phi(s)$を決める結合・バイアスを更新する。
- 両者とも中間層を含めて学習する。

標準偏差は、各行動次元の学習パラメータℓ_jから、次のように求める。

$$\sigma_j = \exp(\ell_j)$$

したがって、Actorの更新では平均だけでなくσも変わり得る。現在のℓ_jはActor損失の勾配で学習する。報酬に基づく別の調整則は未検証であり、置換式はまだ確定していない。

16. 同じRolloutを複数epoch学習する｜経験再利用の除去・回数変更は未検証

全データを一巡することを1epochとし、8〜15を設定回数だけ繰り返す。ActorとCriticは各ミニバッチで更新する。

固定するもの	更新・再計算するもの
収集した状態・行動・報酬	ActorとCriticのパラメータ
収集時の$\log \pi_{\text{old}}$とV_{old}	現在のμ、σ、$\log \pi_\theta$、V_ϕ
A_t^{raw}、A_t^{used}、Y_t、R_{past}	方策比、損失、勾配

17. Running RMSの履歴を更新し、次のRolloutへ進む｜維持

Rollout番号をkとし、今回のAdvantageの二乗平均を求める。

$$Q_k = \frac{1}{T}\sum_{t=0}^{T-1}\left(A_{k,t}^{\text{raw}}\right)^2$$

全epochの学習を終えた後に、履歴M_kを更新する。

$$M_k = (1-\alpha)M_{k-1} + \alpha Q_k$$

αは履歴の更新率。初回は$M_1 = Q_1$とする。次のRolloutで使う尺度は、次のように求める。

$$R_{\text{past}}^{(k+1)} = \max\left(\sqrt{M_k}, R_{\min}\right)$$

$R_{\min} > 0$は小さすぎる尺度を避けるための下限。履歴のない最初のRolloutでは尺度1を使う。

その後、更新後のActorとCriticで次の経験を収集し、AdvantageとCriticの目標も新たに作る。