PPO_flow_component_status

判定の意味

- **除去不可（現時点）**：今回の変更実験では学習がうまくいかなかったため、現在は残す判断。
- **置換可能（確認済み）**：別の処理へ置き換えて学習できたというユーザー報告がある。生理学的対応の確定とは区別する。
- **置換候補（未検証）**：置換案はあるが、学習が成立するかは未確認。
- **未検証**：除去・置換の成否を判断する結果がまだ共有されていない。
- **維持**：現在のモデルで引き続き使用する。

PPO＋Running RMS：処理順と除去・置換の状況

「除去不可（現時点）」は、今回の実験結果に基づいて現在は残すという判断を表す。

使用するパラメータ

記号	内容
θ_μ	Actorの隠れ層・平均出力層の重みとバイアス
ℓ	Actorが保持する、行動の各次元の学習可能な `log_std`
$\sigma = \exp(\ell)$	行動の各次元の標準偏差。指数関数は成分ごとに適用
$\theta = (\theta_\mu, \ell)$	Actor全体のパラメータ
ϕ	Criticの隠れ層・価値出力層の重みとバイアス

現行実装では、平均μは状態から計算し、ℓはネットワーク出力とは別のパラメータとして保持する。σは状態に直接依存しないが、学習によって変化する。

1. Actor・Criticの出力を計算｜維持

状態s_tを入力し、行動分布の平均と状態価値を求める。

$$\mu_{\text{old}}(s_t), \qquad V_{\text{old}}(s_t)$$

oldは「今回のRolloutの収集に使うモデル」を表す。収集中はActor・Criticのパラメータを更新しない。

2. 方策分布を構成し、行動をサンプリング｜σの調整は除去不可（現時点）／更新則は置換候補（未検証）

保持しているℓ_{old}から標準偏差を求め、ガウス方策を構成する。

$$\sigma_{\text{old}} = \exp(\ell_{\text{old}})$$

$$\pi_{\text{old}}(\cdot \mid s_t) = \mathcal{N}\big(\mu_{\text{old}}(s_t), \operatorname{diag}(\sigma_{\text{old}}^2)\big)$$

$$\epsilon_t \sim \mathcal{N}(0, I), \qquad a_t = \mu_{\text{old}}(s_t) + \sigma_{\text{old}} \odot \epsilon_t$$

⊙は成分ごとの積。固定σ条件は複数seedでうまくいかなかったが、到達できた試行もある。報酬に基づくσの調整は置換候補であり、未検証。

3. 環境を1ステップ進める｜維持

行動を環境の入力範囲に制限して渡し、報酬r_t、次状態s_{t+1}、`terminated`、`truncated`を取得する。

- `terminated`：課題そのものの終了条件を満たしたこと。現環境では到達後の評価区間終了など。
- `truncated`：最大ステップ数などの制限により打ち切ったこと。

真の終端では、その先の状態価値による補完を行わない。時間制限による打ち切りでは、打ち切られた時点の状態価値を使って補完する。リセット後の初期状態の価値とは区別する。

4. Rolloutを収集・保存する｜収集方法の変更は未検証

1〜3を`N_STEPS`分繰り返す。Rolloutは1エピソードと一致する必要はなく、エピソードをまたぐことも、途中で収集を区切ることもある。

状態・行動・報酬・エピソード境界に加え、次を保存する。

$$\text{logp}_t^{\text{old}} = \log \pi_{\text{old}}(a_t \mid s_t), \qquad v_t^{\text{old}} = V_{\text{old}}(s_t)$$

$\log \pi_{\text{old}}(a_t \mid s_t)$は、収集した状態・行動に対するlog確率密度。ここではこれらの値を保存すればよく、旧ネットワーク全体を別に保持する必要はない。方策比には、環境の入力範囲に制限する前のサンプルa_tを使う。

5. GAEでAdvantageを計算｜除去・置換は未検証

報酬列と収集時の価値予測から、調整前のAdvantage A_t^{raw}を一度計算する。

今回の収集データを学習している間は固定する。Criticが更新されても、同じRolloutのA_t^{raw}を計算し直さない。

6. Criticの学習目標を作る｜構成・固定手順の置換は未検証

$$Y_t = v_t^{\text{old}} + A_t^{\text{raw}}$$

今回の学習中はY_tを固定し、目標側へ勾配を流さない。

7. Actor用Advantageをスケーリング｜置換可能（確認済み）

$$A_t^{\text{used}} = \frac{A_t^{\text{raw}}}{\text{RMS}_{\text{past}} + \varepsilon_{\text{RMS}}}$$

バッチ内標準化から、過去のRolloutに基づくRunning RMSへ置換済み。正の値で割るため、Advantageの符号を保つ。

RMS_{past}とA_t^{used}は今回の全epochで固定する。Criticの目標Y_tには、スケーリング前のA_t^{raw}を使う。

8. ミニバッチを構成｜勾配集約は除去不可（現時点）

収集データをシャッフルし、`BATCH_SIZE`件ずつ取り出す。各サンプルの損失を平均し、その勾配を使って更新する。

`BATCH_SIZE=1`条件は複数seedでうまくいかなかった。ただし、バッチサイズの変更に伴ってoptimizerの更新回数も変わるため、失敗の原因を勾配平均の有無だけに限定しない。シャッフル自体の必要性は未検証。

9. 現在のActor・Criticで再評価｜維持

保存した同じs_tとa_tについて、現在のパラメータで次を計算する。

$$\text{logp}_t = \log \pi_\theta(a_t \mid s_t), \qquad v_t = V_\phi(s_t)$$

行動の再サンプリングや、環境からの報酬の再取得は行わない。

10. 方策比を計算｜除去・置換は未検証

$$\rho_t(\theta) = \exp\left(\text{logp}_t - \text{logp}_t^{\text{old}}\right) = \frac{\pi_\theta(a_t \mid s_t)}{\pi_{\text{old}}(a_t \mid s_t)}$$

分母に相当する収集時のlog確率密度は固定し、現在のlog確率密度を計算し直す。保存した行動が、収集時と比べてどれだけ出やすくなったかを表す。

11. Actorの損失を計算｜除去・置換は未検証

ミニバッチをB、`CLIP_RANGE`をcとする。

$$L_A(\theta) = -\frac{1}{|B|} \sum_{t \in B} \min\left[\rho_t(\theta) A_t^{\text{used}},\ \text{clip}(\rho_t(\theta), 1-c, 1+c)\, A_t^{\text{used}}\right]$$

Advantageの符号と方策比に応じて、そのサンプルの勾配寄与を制限する。方策の変化量全体を必ず一定範囲内に収める処理ではない。

12. Criticの損失を計算｜維持

$$L_V(\phi) = \frac{1}{|B|} \sum_{t \in B} \left(V_\phi(s_t) - Y_t \right)^2$$

固定したY_tへ、現在の価値予測$V_\phi(s_t)$を近づける。現在の設定では価値関数クリッピングは使わない。

13. 誤差逆伝播で勾配を計算｜維持

$$L = L_A + c_V L_V, \qquad c_V = \texttt{VF_COEF}$$

- Actorのθ_μとℓには、Actor損失から勾配が流れる。
- Criticのϕには、重み付けしたCritic損失から勾配が流れる。
- 保存値$\mathrm{logp}_t^{\mathrm{old}}$、$A_t^{\mathrm{used}}$、$Y_t$には勾配を流さない。

14. 勾配ノルムを制限｜分離への置換可能（確認済み）

Actor側（θ_μ, ℓ）とCritic側（ϕ）の勾配ノルムを、それぞれ別に制限する。

Actor・Criticをまとめて制限する方式から、別々に制限する方式への置換は確認済み。制限自体を完全に除去できるかは未検証。

15. Adamでパラメータを更新｜Adamは維持／σ更新則は置換候補（未検証）

共通optimizerの1回の`step()`で、次を更新する。

更新対象	更新されるもの
θ_μ	Actorの隠れ層・平均出力層の重みとバイアス
ℓ	行動の各次元の`log_std`
ϕ	Criticの隠れ層・価値出力層の重みとバイアス

更新後のℓから標準偏差を求める。

$$\sigma_{\mathrm{new}} = \exp(\ell_{\mathrm{new}})$$

したがって、Actorでは平均μと標準偏差σの両方が変わり得る。Criticの価値予測と、両ネットワークの中間層の活動も変わり得る。

現在のσはActor損失の勾配によって学習する。報酬に基づく別の調整則への置換は、今後の検証対象。

16. 同じデータをN_EPOCHS周学習｜再利用の除去・回数変更は未検証

収集データ全体を一巡することを1epochとし、8〜15を繰り返す。ActorとCriticの周回数は共通。

今回のRolloutの学習中に固定するもの	更新・再計算するもの
保存した状態・行動・報酬、$\mathrm{logp}_t^{\mathrm{old}}$、$v_t^{\mathrm{old}}$、$A_t^{\mathrm{raw}}$、$A_t^{\mathrm{used}}$、$Y_t$	現在のパラメータ、μ、σ、logp_t、$V_\phi(s_t)$、方策比、損失、勾配

ActorとCriticは各ミニバッチで一緒に更新される。

17. 履歴を更新し、次のRolloutへ｜維持

現在のA_t^{raw}をRunning RMSの履歴へ一度反映する。その後、更新後のActor・Criticで次のRolloutを収集する。

次のRolloutでは、$\mathrm{logp}_t^{\mathrm{old}}$、$v_t^{\mathrm{old}}$、$A_t^{\mathrm{raw}}$、$Y_t$を新たに作る。oldの基準はRolloutごとに更新される。