PPOの流れと脳との対応｜1〜17の解説

状態を大脳皮質で処理し、線条体から行動分布の平均と状態価値を出す。Actorは行動を提案し、Criticはその状態から先に得られる報酬を予測する。

経験を集めた後に各提案を評価し、過去の状態と提案を学習時に再び使う。Actorは評価のよかった提案を選びやすくし、Criticは現在の価値予測を固定目標へ近づける。SNc出力をraw Advantage、GPeの作用を提案の変動の調整に対応させる。

目指すのは、PPOから着想を得た皮質・大脳基底核の運動学習モデルである。

番号	処理	脳との対応・現在の扱い
1	状態を入力し、行動分布の平均と状態価値を求める	最終層の対応を検討。入力・中間層は皮質、Actor・Criticの結合は別々。
2	標準偏差を定め、各関節の分布から提案を選ぶ	σの調整は除去不可（現時点）。GPeとの対応は仮説。別の調整則は未検証。
3	提案から運動を行い、報酬と次状態を得る	提案と実際のトルクを区別する。直接路・間接路・GPiの役割は回路仮説。
4	重みを変えずに一定量の経験を集め、保持する	正確な数値情報の保持・再提示をモデル仮定として置く。海馬は候補。
5	収集した経験からraw Advantageを計算する	SNc＝raw Advantageは仮説。収集後に計算し、反復学習中は固定。
6	旧価値とraw AdvantageからCriticの目標を作る	同じ経験では目標を固定。保存済みの2値から毎回作ってもよい。
7	Actorに使うAdvantageだけを、過去のRMSで調整する	置換可能（確認済み）。DAを受け取るActor側の履歴依存ゲインと解釈。
8	経験をミニバッチに分ける	除去不可（現時点）。学習を安定させる工学的処理として維持。
9	保存した状態を現在のモデルへ入力し直す	経験の再提示で現在価値を得る。数値情報の正確な再提示はモデル仮定。
10	収集時と現在の方策が、同じ提案へ与える確率密度を比較する	旧対数確率を固定。方策比の生理学的な実現方法は未特定。
11	Advantageと方策比からActorの学習方向を決める	最終層の勾配と三要素更新を対応づける。比・クリッピングの機構は未特定。
12	固定目標と現在の価値を比較し、Criticを学習する	比較機能を作業仮説として置く。明示的な二乗計算の回路は必須ではない。

番号	処理	脳との対応・現在の扱い
13	ActorとCriticの勾配を計算する	維持。パラメータを共有しないため、勾配の由来は各々の損失に分かれる。
14	ActorとCriticの勾配ノルムを別々に制限する	分離への置換可能（確認済み）。各ネットワーク全体の情報が必要な点は残る。
15	Adamで結合と標準偏差のパラメータを更新する	Adamは維持。平均・価値だけでなく、中間層とσも学習する。
16	同じ経験を複数回使い、ActorとCriticを反復学習する	リプレイ＋DAを機能仮説とする。オフライン学習でDAの遅延やトレースは必須としない。
17	RMSの履歴を更新し、新しいモデルで次の経験を集める	RMSは全epoch終了後に更新。新しい平均・σ・価値で次の収集へ進む。

1. 状態を入力し、行動分布の平均と状態価値を求める

状態‘s_t‘には、その時点の関節角度や速度など、課題を行うための情報が含まれる。これをActorとCriticにそれぞれ入力する。

Actorは、後で行動提案を選ぶための分布の平均‘$\mu(s_t)$‘を出す。Criticは、その状態から先に得られる割引累積報酬の予測‘$V(s_t)$‘を出す。Criticは「今までに得た報酬」を計算するのではなく、「ここから先にどれくらい得られそうか」を予測する。

本モデルでは、両者とも入力層と中間層を大脳皮質、線形の最終層を線条体に対応させる。Actorの皮質活動を‘x_i‘、Criticの皮質活動を‘z_i‘とすれば、

$$\mu_j(s_t) = \sum_i W^A_{ij} x_i(s_t), \qquad V(s_t) = \sum_i w^C_i z_i(s_t)$$

と表せる。ActorとCriticを同じ「皮質・線条体」という部位名で説明しても、学習する結合は共有しない。

Criticと線条体を対応させる根拠：鮫島の「強化学習と大脳基底核の整理」

背景・目的： 将来の報酬を予測する機能と、その予測に基づいて行動を選ぶ機能を、大脳基底核の回路へどう対応させるかを考える。

整理の内容： この整理では、線条体のStriosome系を、状態価値を構成する情報を表すCritic側の機構として捉える。個々の細胞がそのまま一つの価値を出すという説明ではなく、細胞の活動を価値計算の部品として扱い、それらを投射先で重み付きに統合する考え方である。

今回の使い方： 状態価値の評価に線条体が関わることを、Criticの最終層を線条体へ置く根拠にする。本モデルは、皮質入力を線条体に対応させた最終層で統合して

‘$V(s)$‘を読み出すように簡略化している。価値を最終的に統合する場所まで、鮫島の整理と同一にしたわけではない。

強化学習と大脳基底核の整理(鮫島）

2. 標準偏差を定め、各関節の分布から提案を選ぶ

平均だけでは、どの提案をどの程度試すかは決まらない。そこで、各関節‘j‘について標準偏差‘σ_j‘を用意する。現行では、学習するパラメータ‘ℓ_j‘から、

$$\sigma_j = \exp(\ell_j)$$

と求める。‘σ_j‘は関節ごとに異なってよいが、状態を入力するたびにネットワークが出す量ではない。学習によって変わる、状態に直接依存しない量である。

各関節について、平均‘$\mu_j(s_t)$‘、分散‘σ_j^2‘のガウス分布から提案‘$q_{j,t}$‘を1つ選ぶ。

$$q_{j,t} \sim \mathcal{N}\big(\mu_j(s_t), \sigma_j^2\big)$$

2関節なら、それぞれの分布から1つずつ選び、組‘$q_t = (q_{1,t}, q_{2,t})$‘を得る。このモデルの条件付き確率密度は、

$$\pi(q_t \mid s_t) = \prod_{j=1}^{2} \mathcal{N}\big(q_{j,t}; \mu_j(s_t), \sigma_j^2\big)$$

となる。「2成分を合わせて一つの提案と呼ぶ」ことは、関節ごとにサンプリングする説明と両立する。2つの関節が互いを抑制して片方だけ動く、という意味ではない。

本モデルでは、線条体の平均駆動と、GPeからの作用で調整される変動によって提案が決まると考える。GPeがガウス分布の標準偏差を調整する部分は仮説である。

GPeから線条体への作用の根拠：Mallet et al.（2016）

背景・目的： 始めようとした行動を止めるとき、GPeから線条体へ戻る経路がどのように働くかを調べた。

手法・結果： 行動停止課題中の神経記録や回路の検討から、線条体へ投射するGPe細胞が、停止に伴う線条体活動の抑制に関わることを示した。

今回の使い方： GPeが線条体の活動を調整できる根拠にする。ガウス分散の計算や‘$1/\sigma^2$‘による除算を実装する証拠にはしない。

GPeから線条体へ戻る信号と行動停止（Mallet et al., 2016）

固定‘σ‘の実験は複数seedで安定した学習に至らなかったため、現時点では‘σ‘の調整を残す。報酬に基づく別の調整則へ置き換える案は、まだ検証していない。

3. 提案から運動を行い、報酬と次状態を得る

線条体が出す‘q_t‘は行動の提案であり、筋や関節に与えるトルクそのものとは区別する。本モデルで想定する順番は次のとおりである。

1. 線条体が行動を提案する。
2. 直接路が提案を支持し、間接路が競合する提案を抑える。
3. GPi/SNrでそれらの作用が統合され、運動の選択へつながる。
4. その後の回路で、実際の運動指令へ変換される。

現行のシミュレーションは2成分の出力を関節トルクに使うが、直接路・間接路・GPiの競合を別々の計算として実装してはいない。したがって、この回路の説明は現行計算へ与える解釈であり、各段階を実装済みと扱わない。

運動の後に、報酬‘r_t‘と次状態‘s_{t+1}‘を得る。また、経験を評価するために、そこで課題が本当に終了したのか、途中で時間制限に達したのかを区別する。

真の終了では、その先の報酬を0とする。課題の途中を外部の制限時間で打ち切った場合は、打ち切り時点の価値予測から、その先を見積もる。リセット後の別エピソードの状態を、元の経験の次状態として使ってはいけない。

GAEの計算：後の結果を、前の行動の評価へ反映する

4. 重みを変えずに一定量の経験を集め、保持する

1〜3を繰り返す間は、ActorとCriticの重みを更新しない。このときのモデルを「収集時のモデル」とし、式ではoldを付ける。

一定区間に集めた経験のまとまりをRolloutと呼ぶ。各時点について、少なくとも次を保持する。

$$s_t,\ q_t,\ r_t,\ \log \pi_{\mathrm{old}}(q_t \mid s_t),\ V_{\mathrm{old}}(s_t)$$

次状態や、課題の終了・打ち切りの位置も、後の価値計算に使えるようにする。

‘$\log \pi_{\mathrm{old}}(q_t \mid s_t)$‘は、収集時の方策が、その状態で実際に選んだ提案‘q_t‘へ与えた確率密度の対数である。方策全体をそのまま保存しなくても、この値を保持すれば10の方策比の分母を計算できる。

記憶と経験の再生に関わる仕組みの候補として、海馬と関連する回路を考える。PPOに必要な値を正確に保持し、学習時に同じ経験へ対応づけて取り出せることは、モデル仮定として置く。

経験を再び使う時間は、睡眠中に限定しない。 海馬では、起きたまま動きを止めている間にも、直前の経験に対応する活動系列が現れる。今回のモデルでは、覚醒中の休止と睡眠の両方を、経験を再提示する期間の候補に含められる。

海馬と線条体が休止中に経験を再現する根拠：Lansink et al.（2009）

背景： 場所と報酬を結び付けた経験を記憶するには、場所に関係する海馬と、報酬に関係する線条体の情報を結び付ける必要がある。

目的： 行動中に見られた海馬と腹側線条体の活動の関係が、その後の休止中にも現れるかを調べる。

手法： ラットの報酬探索課題中と、その前後の休止期間に、海馬と腹側線条体の細胞を同時に記録した。行動中の細胞の活動の組合せや発火の順番が、課題後にも現れるかを解析した。主な解析区間には静かな覚醒が含まれ得るため、著者らは徐波睡眠とまとめてQW-SWSと呼んでいる。

結果： 行動中に場所と報酬に関係して活動した海馬・腹側線条体の細胞が、課題後の休止中にも協調して活動した。海馬の細胞が先に発火する組が多かった。

考察： 著者らは、場所と報酬の関連を記憶へ定着させる仕組みの候補と考えた。本モデルでは、経験に関係する活動を海馬だけで完結させず、線条体側の活動へつなげる根拠として使う。ただし、覚醒中だけ、または睡眠中だけで確認した結果とは扱わない。

海馬と線条体が休止中に経験を再現する（Lansink et al., 2009）

覚醒中の再生、睡眠中の結果、海馬以外での再生、DAとの組合せを、次のページにまとめる。正確なPPOの数値情報を保持・再提示できる点は、引き続きモデル仮定とする。

海馬・リプレイ：覚醒中の休止、睡眠、線条体とDA

5. 収集した経験からraw Advantageを計算する

Advantageは、その状態で普段どおり行動する場合と比べて、今回の提案がどれくらいよかったかを表す。ここではGAEで求めた値を、調整前の‘A_t^{raw}‘と呼ぶ。

まず、報酬と収集時の価値予測からTD誤差を求める。

$$\delta_t = r_t + \gamma V_{\mathrm{old}}(s_{t+1}) - V_{\mathrm{old}}(s_t)$$

真の終端では次状態価値を0にする。続いて、同じエピソード内の収集データを後ろからたどり、

$$A_t^{\mathrm{raw}} = \delta_t + \gamma\lambda A_{t+1}^{\mathrm{raw}}$$

と計算する。終了・打ち切り・収集区間の末尾では、後続のAdvantageをつなげない。

行動直後にはまだ見えていなかった結果も、収集後なら使える。本モデルでは、行動中に最終的なGAEを得ようとせず、経験を集めてから評価し、その評価を後の学習時に取り出す。

GAEを使う理由：Schulman et al.（2015／2016）

背景・目的： 1ステップのTD誤差は価値予測の誤りに影響される一方、遠い先の報酬までそのまま使うと推定のばらつきが大きくなる。この両者を調整するためにGAEが提案された。

手法・結果： 後続のTD誤差を重み付きで足す推定式を導き、連続制御課題で方策学習を評価した。‘λ‘で、価値予測への依存と、長い時間先の情報の利用を調整できる。

今回の使い方： 各経験へ、後の結果も含めた固定の評価を付ける。GAEの計算そのものに生理学的実証があるという意味ではない。

GAE：後の結果を使って各行動を評価する（Schulman et al., 2015／2016）
GAEの計算：後の結果を、前の行動の評価へ反映する

SNc出力を‘A_t^{raw}‘に対応させる。DA濃度が負になると考えるのではなく、基準からの増減や集団活動の読み出しで符号を表すと考える。この符号の表し方の具体化も、モデル仮定に含まれる。

6. 旧価値とraw AdvantageからCriticの目標を作る

Criticの目標を、次のように定める。

$$Y_t = V_{\mathrm{old}}(s_t) + A_t^{\mathrm{raw}}$$

収集時に予測した価値へ、その後の結果からわかった修正分を加える形である。

たとえば旧価値が2、raw Advantageが1なら、目標は3になる。Criticが学習して現在の予測を2.5に変えても、この経験の目標は3のままである。

目標‘Y_t‘そのものを事前に保存する必要はない。更新のたびに、同じ経験に対応する旧価値とraw Advantageを取り出して足してもよい。大切なのは、足す2つの値を

現在のモデルで作り直さないことである。

脳との対応では、記憶から得る旧価値と、SNc出力に対応させたraw Advantageを組み合わせると仮定する。現在のCritic予測を得る方法は9、目標との比較は12で扱う。

7. Actorに使うAdvantageだけを、過去のRMSで調整する

置換前は、ミニバッチ内のAdvantageの平均‘$\bar{A}_B$‘を引き、標準偏差‘s_B‘で割っていた。

$$A_t^{\text{used}} = \frac{A_t^{\text{raw}} - \bar{A}_B}{s_B + \varepsilon}$$

置換後は、過去のRolloutから求めたRMSを使う。

$$A_t^{\text{used}} = \frac{A_t^{\text{raw}}}{R_{\text{past}} + \varepsilon}$$

RMSは、値を二乗して平均し、その平方根を取った大きさの尺度である。正の値で割るので、raw Advantageの符号を変えない。今回の全epochでは同じ‘R_{past}‘を使う。Criticの目標はraw Advantageで作り、この調整を加えない。

生理学的には、SNc出力そのものを変えるのではなく、Actorに対応する線条体集団がDAを受け取った後の作用の強さを変える、と考える。過去の刺激を反映する細胞側の状態によって、同じDA信号でも可塑性への作用が変わる。その変化をRunning RMSで近似する。

過去のDA刺激で、その後の反応が変わる根拠

背景・目的： DAを受け取る細胞の反応は一定なのか、それとも、それまでに受けたDA刺激によって変わるのかが問題になる。

手法・結果： Trovero et al.（1994）は、培養線条体細胞をDAで刺激し、洗浄後に再び刺激して、細胞内の信号を伝える物質cAMPを測った。先行刺激で弱まった反応は時間とともに回復し、グルタミン酸は回復を速めた。Kim et al.（2000）はDA不足マウスを用い、受容体に作用する薬剤への反応が通常より強くなり、反復DA補充で弱まることを示した。

今回の使い方： 受信側の反応が、過去の刺激に応じて弱まるだけでなく、回復したり強くなったりする根拠にする。ただし、培養細胞やDA不足マウスの結果から、通常の学習でRMSに一致する可塑性調整が行われるとまでは言えない。

過去のDA刺激で弱まった応答は回復する（Trovero et al., 1994）
DAが不足すると反応が強くなり、補充で戻る（Kim et al., 2000）
過去のDA刺激が次の応答を変える（Chneiweiss et al., 1990）

二乗・平均・逆平方根の計算と、Actorだけに作用させる点は、モデル側で置く近似である。

Running RMSの計算と、DAを受け取る側の履歴

8. 経験をミニバッチに分ける

収集した経験の順番をシャッフルし、その一部をまとめて取り出す。このまとまりがミニバッチである。

1件の経験から得られる勾配を‘g_t‘、ミニバッチを‘B‘とすると、更新に使う勾配は、

$$g_B = \frac{1}{|B|} \sum_{t \in B} g_t$$

になる。たとえば512件を使う場合、512回の個別更新を行うのではなく、512件から得た勾配の平均で1回更新する。

ミニバッチを1件にした実験では、到達できる時期があっても、安定停止と性能維持には至らなかった。また、1件ずつにすると更新回数も増えるため、失敗を「平均がないこと」だけで説明できない。

当面は、ミニバッチを学習安定化のための工学的処理として維持する。脳が同じ件数を同時に平均すると主張する必要はない。追加のバッチ除去実験を、この対応づけを進めるための必須条件にはしない。

9. 保存した状態を現在のモデルへ入力し直す

保存された状態‘s_t‘を、学習時点のActorとCriticに入力する。これにより、現在の平均‘$\mu_{\text{current}}(s_t)$‘と価値‘$V_{\text{current}}(s_t)$‘を求める。現在の標準偏差も使い、保存された提案‘q_t‘の対数確率密度を求める。

$$\log \pi_{\text{current}}(q_t \mid s_t), \qquad V_{\text{current}}(s_t)$$

‘q_t‘を新しく選び直す処理ではない。同じ過去の状態と提案を、今のモデルならどう扱うかを計算する。

したがって、Criticの「現在の予測」を記憶から取り出す必要はない。記憶から過去の状態を取り出し、現在の皮質・線条体の結合を通して計算し直せばよい。

過去の経験を皮質・線条体の活動へ結びつける根拠

背景・目的： 運動を練習した後、実際には動いていない睡眠中にも、練習時の神経活動や皮質と線条体の関係が現れるかを調べた研究がある。

手法・結果： Ramanathan et al.（2015）は、運動課題の前後と睡眠中の運動皮質を記録し、練習中の活動パターンが睡眠中にも現れ、その程度が後の成績改善と関係することを示した。Lemke et al.（2021）は運動皮質と背外側線条体を同時記録し、練習後の睡眠中に両者の活動の結びつきが変化することを調べた。

今回の使い方： 経験を思い返すような内部活動によって、学習に関係する皮質・線条体の活動を再び生じさせる、という仮説の根拠にする。これらの研究が、過去の状態ベクトルを入力して現在価値を計算したことを直接示すわけではない。

運動中の皮質活動が睡眠中にも現れる（Ramanathan et al., 2015）
練習後の睡眠中に皮質と線条体の関係が変わる（Lemke et al., 2021）

この2本の主要な根拠は、ノンレム睡眠中の運動回路に関するものである。覚醒中にも海馬のリプレイがあることと、同じ皮質線条体の学習機構が覚醒中にも働くことは分けて考える。ここには皮質・線条体に直接関わる説明を残し、海馬側の文献と実験条件の比較は次にまとめる。

海馬・リプレイ：覚醒中の休止、睡眠、線条体とDA

10. 収集時と現在の方策が、同じ提案へ与える確率密度を比較する

同じ状態‘s_t‘と提案‘q_t‘について、方策比を求める。

$$\rho_t = \frac{\pi_{\text{current}}(q_t \mid s_t)}{\pi_{\text{old}}(q_t \mid s_t)} = \exp[\log \pi_{\text{current}}(q_t \mid s_t) - \log \pi_{\text{old}}(q_t \mid s_t)]$$

‘$\rho_t > 1$‘なら、現在のActorは収集時よりその提案へ高い確率密度を与えている。‘$\rho_t < 1$‘なら、低い密度を与えている。更新を始める直前は、現在のActorと収集時のActorが同じなので、おおむね1になる。

分母に使う収集時の値は固定し、分子だけを現在のActorで計算し直す。これは6の固定目標と役割が異なる。旧価値はCriticの目標を決め、旧対数確率はActorの変化を測る基準になる。

2関節の独立なガウス分布なら、対数確率密度は各関節の値の和になる。

$$\log \pi(q_t \mid s_t) = \sum_{j=1}^{2} \log \mathcal{N}(q_{j,t}; \mu_j(s_t), \sigma_j^2)$$

現行では、この組全体の方策比を11でクリップする。関節ごとに別の比を作って別々にクリップする方式ではない。

脳のどこで旧対数確率を保持し、現在の密度と比較するかは未特定である。記憶の利用は仮定しているが、そのことだけで方策比の計算回路まで説明できたとはしない。

11. Advantageと方策比からActorの学習方向を決める

Actorの基本的な学習は、‘$A^{\mathrm{used}} > 0$‘なら保存された提案‘q_t‘の確率密度を上げ、負なら下げることである。同じ経験を反復利用すると変更が進むため、PPOでは方策比にクリッピングを加える。

クリッピング幅を‘c‘として、最小化する損失を次のように定める。

$$L_A = -\frac{1}{|B|}\sum_{t\in B}\min\left[\rho_t A_t^{\mathrm{used}},\ \mathrm{clip}(\rho_t,1-c,1+c)A_t^{\mathrm{used}}\right]$$

正のAdvantageの提案をすでに十分選びやすくした場合、または負のAdvantageの提案を十分選びにくくした場合、その経験からさらに同じ向きへ進める勾配を止める。ただし、すべての方策比が範囲内に収まる保証ではない。

クリッピングで勾配が止まる場合を除くと、平均を作る最終層の勾配には、

$$A_t^{\mathrm{used}} x_i(s_t)\frac{q_{j,t}-\mu_j(s_t)}{\sigma_j^2}$$

という因子が現れる。実際にはここに方策比とクリッピングの係数が掛かる。

この形から、皮質入力‘x_i‘、線条体側の提案と平均駆動との差、DAに対応させた評価信号を組み合わせる学習として考える。式が現在の活動を使う点、平均との差と逆分散が必要な点は、仮説の中でも説明すべき部分として残る。

皮質線条体結合とDA依存の可塑性の根拠

背景・目的： 報酬に関係するDAが、皮質から線条体への結合の学習にどう関与するかが問題になる。

手法・結果： Reynolds et al.（2001）は、皮質入力への線条体の反応を測定し、黒質の刺激とDAに関係する作用が結合の増強に関わることを示した。Shen et al.（2008）は、D1・D2細胞を区別した脳切片で入力と発火の時間関係や受容体への作用を操作し、条件によって結合が強くも弱くもなることを示した。

今回の使い方： 局所活動とDAに関係する信号が結合変化へ関与する根拠として使う。活動差、逆分散、方策比、クリッピングが、これらの実験で実証されたとはしない。

黒質の刺激とDA作用で皮質線条体結合が変わる（Reynolds et al., 2001）
線条体の結合は条件によって強くも弱くもなる（Shen et al., 2008）

PPOのクリッピングの背景・目的： 同じ経験を複数回使いながら、一度の収集で方策を過度に変えないことを目指す。Schulman et al.（2017）は、クリップした目的関数を用いて連続制御などの課題を評価した。この論文は工学的な学習則の根拠であり、生理機構の根拠とは分ける。

PPO：同じ経験を繰り返し使って方策を学習する（Schulman et al., 2017）
Actor最終層の更新：皮質入力・提案と平均の差・DA信号

12. 固定目標と現在の価値を比較し、Criticを学習する

Criticは、現在の予測‘$V_{\text{current}}(s_t)$‘を6の目標‘Y_t‘へ近づける。必要なのは、次の符号付き誤差である。

$$e_{C,t} = Y_t - V_{\text{current}}(s_t) = A_t^{\text{raw}} - [V_{\text{current}}(s_t) - V_{\text{old}}(s_t)]$$

誤差が正なら予測を上げ、負なら下げる。目標に一致すれば0になる。

raw Advantageは、同じ経験では固定である。Critic誤差は、学習が進んで現在の予測が変わるたびに変わる。この2つを同じ信号として扱わない。

たとえば旧価値2、raw Advantage1なら目標は3。現在の予測が2から2.7へ進めば、必要な修正は1から0.3へ減る。3.4まで上がりすぎれば、誤差は−0.4へ反転する。この補正を、固定のDA信号に対する正のゲイン調整だけで作ることはできない。

そこで本モデルでは、raw Advantageを受け取り、「現在価値−旧価値」を差し引く比較機能を、Critic受信側などに仮定する。具体的な場所と伝達経路はまだ決めていない。

二乗誤差との関係

学習計算では、価値の二乗誤差を小さくする。

$$L_V = \frac{1}{|B|} \sum_{t \in B} \left(V_{\text{current}}(s_t) - Y_t \right)^2$$

線形の最終層では、損失を減らす方向の勾配は、正の定数係数を除いて、

$$e_{C,t}\, z_i(s_t)$$

になる。‘z_i‘はCritic側の皮質入力である。「誤差を二乗する回路」を置く代わりに、符号付き誤差と皮質入力で結合を変えるという説明ができる。価値関数のクリッピングは使わない。

神経回路による減算の根拠：Eshel et al.（2015）

背景・目的： DA細胞は、予想した報酬より予想外の報酬に強く反応する。その違いを、予測情報の引き算で作るのかを調べた。

手法・結果： 報酬を予測する匂いを使った課題で、VTAのDA細胞とGABA細胞を記録・操作した。予測による応答の減少は減算で説明され、GABA細胞の操作がその減少に関与することが示された。

今回の使い方： 予測に関係する情報を引き、誤差を作ることが神経回路で可能だという根拠にする。この研究はVTAでの計算であり、本モデルの線条体側の比較回路を実証したものではない。

予測の情報を引いてDAの誤差応答を作る（Eshel et al., 2015）

Criticと線条体の対応は1で挙げた鮫島の整理を根拠とし、比較の計算はEshel、結合の変化は11のReynolds・Shenで支える。これらを組み合わせてCriticの大枠を説明するが、完成したPPO Critic回路が見つかっているわけではない。また‘e_C‘を作る追加の比較があるため、固定DAをそのまま掛けるだけの三要素則とは区別する。

Criticの比較と学習：固定目標と現在の予測の差を使う

13. ActorとCriticの勾配を計算する

Criticの損失に掛ける重みを‘c_V‘として、合計損失を定める。

$$L = L_A + c_V L_V$$

Actorのパラメータを‘θ‘、Criticのパラメータを‘ϕ‘とすると、勾配は、

$$g_A = \nabla_\theta L = \nabla_\theta L_A, \qquad g_C = \nabla_\phi L = \nabla_\phi (c_V L_V)$$

となる。ActorとCriticはパラメータを共有せず、Advantageと目標も固定値として扱うため、相手側の損失から勾配は来ない。

処理としては、合計損失について誤差逆伝播を1回行う。その結果、各パラメータに対応する勾配が得られる。Actor用とCritic用に別々の誤差逆伝播へ置き換えたわけではない。

収集時の対数確率、旧価値、Advantage、目標を、今回の更新によって変えることはしない。誤差逆伝播は当面の工学的処理として維持し、生理学的な説明は最終層から進める。

14. ActorとCriticの勾配ノルムを別々に制限する

ここで制限するのは、13で求めた勾配の大きさである。

置換前は、ActorとCriticの勾配をまとめたノルムが上限を超えると、両者を同じ係数で縮小していた。そのため、Criticの勾配が大きいだけでActorの勾配も小さくなり得た。

置換後は、ActorはActor自身のノルムと上限‘C_A‘、CriticはCritic自身のノルムと上限‘C_C‘で縮小する。

$$\tilde{g}_A = \frac{C_A}{\max(C_A, \|g_A\|_2)} g_A, \qquad \tilde{g}_C = \frac{C_C}{\max(C_C, \|g_C\|_2)} g_C$$

この分離後も学習できたことは確認されている。

ただし、各ネットワーク内では、全パラメータの勾配の大きさをまとめる必要がある。それを脳のどこで計算し、各結合へ作用させるかは説明できていない。当面は工学的な制限として残す。制限の完全除去は未検証である。

また、これはAdamに渡す前の勾配の制限であり、最終的な結合変化量を直接同じ上限以下にする処理ではない。

ActorとCriticで勾配ノルムを別々に制限する

15. Adamで結合と標準偏差のパラメータを更新する

制限した勾配を使い、AdamでActorとCriticのパラメータを更新する。共通のAdamを使うが、パラメータは共有していない。

Actorでは、状態から平均‘$\mu(s)$‘を計算する入力・中間・最終層の結合やバイアスを更新する。さらに、各関節の‘ℓ_j‘もActor損失から更新するため、

$$\sigma_j = \exp(\ell_j)$$

も変わり得る。したがって、次に同じ状態を評価しても、分布の平均だけでなく幅も変わる。

Criticでは、状態から価値‘$V(s)$‘を計算する各層の結合やバイアスを更新する。

最終層の式を皮質線条体結合の学習として説明していても、シミュレーションが最終層だけを学習しているわけではない。皮質に対応させた中間層も変わり、そこから線条体へ入る特徴も変わる。

Adamと、現行の‘σ‘の学習方法は維持する。報酬に応じたGPeの作用で‘σ‘を調整するという生理学的な説明と、現行の損失勾配で‘ℓ_j‘を更新する計算は、まだ同じ規則として示せていない。

16. 同じ経験を複数回使い、ActorとCriticを反復学習する

収集した経験をミニバッチに分け、8〜15を全データについて行うことを1epochと呼ぶ。設定した回数だけepochを繰り返し、同じ経験でActorとCriticの両方を学習する。

反復学習中に固定するもの	更新・再計算するもの
状態・提案・報酬	ActorとCriticの結合、Actorの標準偏差
収集時の対数確率と旧価値	現在の平均・価値・対数確率
raw AdvantageとCritic目標	方策比、Actor損失、Critic誤差
過去のRMSとActor用Advantage	勾配と、そのノルム制限

生理学的には、過去の状態や提案に関係する活動を皮質・線条体で再び生じさせ、その経験に対応するDA信号を組み合わせると考える。SNcが固定raw Advantageを表し、経験ごとに対応した信号を再び出せることは仮定する。

経験を再提示する時間と、DA信号を組み合わせる根拠

ここでいう学習期間は、睡眠だけを意味しない。起きたまま休んでいる間の海馬リプレイにも根拠がある。一方、運動皮質と線条体の学習について今回使うRamanathan・Lemkeの主要な結果は、睡眠中のものである。

海馬の活動とDA放出が休息中に連動する根拠：Janssen et al.

背景： 経験に関係する神経活動が休息中に現れても、それが報酬に基づく学習につながるには、評価に関係する信号と組み合わされる仕組みが必要になる。DAはその信号の候補である。

目的： 海馬の鋭波リップルと、腹側線条体に放出されるDAが連動するかを調べる。鋭波リップルは、経験の再生が起こることのある短い海馬の活動である。

手法： 自由に行動するマウスで、海馬CA1の電位からリップルを検出し、同時に蛍光センサーで腹側線条体のDAを測定した。課題外の休息と、課題中に動きを止めている時間を比較した。

結果： リップル後にDAが増加し、その連動は課題外の休息中で明瞭だった。また、長く強いリップルの後ほど、DAの増加も大きかった。

考察： 著者らは、脳内で生じる海馬の活動が、経験を評価する信号と結び付く仕組みの候補と考えた。本モデルでは、行動していない時間にも、経験に関係する活動とDA信号を組み合わせられる可能性の根拠にする。ただし、課題外の「休息」を睡眠または覚醒のどちらか一方と同一視しない。参照する第2版は査読前の原稿である。

休息中の海馬活動と線条体のDA放出が連動する（Janssen et al.）

リップルで何の経験が再生されたか、DAがSNc由来か、raw Advantageを表すかは、この結果だけからは決まらない。関連論文の実験条件と今回の役割は、次のページでまとめて比較できる。

海馬・リプレイ：覚醒中の休止、睡眠、線条体とDA

DAが後から来なければならないか

本モデルでは、既に評価済みの経験を再提示する。したがって、局所活動と学習信号を対応づけて同時期に与えられれば、DAが必ず遅れて到来する必要はない。

行動から報酬までに時間が空く場合、その間にどの結合が活動したかを短時間保持する仕組みとして適格性トレースが役立つ。一方、今回のオフライン案では、それを必須部品として追加しない。三要素型の学習を考えることと、明示的な適格性トレースを実装することは別である。

ミニバッチ平均や厳密な反復回数までを、リプレイの実験が直接支持するとはしない。

17. RMSの履歴を更新し、新しいモデルで次の経験を集める

今回の全epochを終えてから、raw Advantageの二乗平均を求める。Rollout番号を‘k‘とすると、

$$Q_k = \frac{1}{T}\sum_{t=0}^{T-1}(A_{k,t}^{\mathrm{raw}})^2$$

である。過去の履歴‘M_{k-1}‘に、更新率‘α‘で取り込む。

$$M_k = (1-\alpha)M_{k-1} + \alpha Q_k$$

次のRolloutで使う尺度は、

$$R_{\text{past}}^{(k+1)} = \max\left(\sqrt{M_k}, R_{\min}\right)$$

とする。最初のRolloutは尺度1で学習し、終了後に‘$M_1 = Q_1$‘で履歴を初期化する。

同じRolloutを何epoch学習しても、RMSの履歴更新は終了後の1回だけである。反復回数の多さを、そのまま新しい経験の多さとして数えない。

その後、更新済みのActorとCriticで1〜4へ戻る。新しい平均と標準偏差で提案を選び、新しい価値予測を記録する。この新しい収集時点の値が、次の学習にとってのoldになる。

RMSを通じた受信側の調整という生理学的な解釈は7の仮説につながる。ただし、細胞内の履歴がRolloutごとの平均として更新されることや、再提示中のDAが履歴に加わらないことまで、生理学的に確認されたわけではない。

Running RMSの計算と、DAを受け取る側の履歴

論文と計算の詳しい説明

根拠となる論文

式と計算例